

基于知识规则框架的物理竞赛解题过程自动化检查研究

一、研究背景与意义

近年来，大语言模型（Large Language Models, LLMs）在数学与物理推理任务中展现出显著能力。而随着思维链（Chain-of-Thought）的提出的与应用（Wei et al., 2022），大语言模型在竞赛级问题的逐步推理中也取得了突破性的进展。然而，模型生成的解题过程往往存在隐性建模错误、情境错配或推理链条断裂等问题，而这些错误并不一定直接显式体现在解题步骤中，却可能导致错误的最终结论。因此，如何构建一个能够对模型解题过程进行系统性、结构化、可扩展检查的机制，成为当前大模型可靠性研究中的关键问题之一。

现有研究主要集中于两类方向：一是通过更强模型进行语言层面的再评估或自一致性验证（self-consistency）（Wang et al., 2023）；二是借助符号系统或形式化验证工具进行校验（Polu & Sutskever, 2020）。前者依赖强模型本身所具备的问题求解能力，难以外部化为稳定可复用的知识体系；后者虽然具有可解释性与确定性优势，但在面对物理竞赛问题高度多样化的情境时，纯符号化建模面临复杂度的挑战。

面对物理竞赛题场景中高层次的建模错误、情境错配和推理过程中的不一致情况，单纯符号验证难以做到对于错误情形的完全覆盖，而单纯语言验证又缺乏稳定性与泛化性。

因此，本研究提出一种“知识规则框架+ 符号化检查模板”的混合式检查机制。其核心思想是：将语言模型隐含的推理能力，通过错误分析与规则提炼转化为可复用的检查规则；同时构建自顶向下的知识规则体系，使经验规则能够归入更本质的物理知

识结构中；在此基础上，应用符号化的检查模板来对解题步骤进行细粒度的符号检查。这一方法既保留语言表达的语义丰富性，又兼容符号逻辑的可验证性。

本研究具有以下意义：

1. 提升小模型的推理可靠性：通过知识规则的外部化，使弱模型在不具备完整解题能力的情况下具备过程检查能力。
2. 促进大语言模型可解释性发展：方法框架与物理规则直接接轨，有助于分析模型错误来源，并在此基础上提升模型在物理推理任务中的表现。
3. 为科学智能提供新范式：将语言推理能力提炼为可迭代知识体系，契合神经-符号融合方向（Garcez et al., 2019）。

二、国内外研究现状

1. 大语言模型的可解释性研究

随着大语言模型（Large Language Models, LLMs）在复杂推理任务中的能力不断提升，其推理过程的可解释性与可靠性逐渐成为研究重点。尤其在数学与物理等科学问题求解中，模型往往需要进行多步逻辑推导、符号计算与情景建模，仅依赖最终答案难以评估推理过程的正确性。因此，近年来研究逐渐关注显式推理过程（reasoning trace）及其自动化验证机制。

Wei 等人提出的 Chain-of-Thought (CoT) prompting 表明，通过生成自然语言形式的逐步推理过程，可以显著提升模型在复杂推理任务中的表现（Wei et al., 2022）。这一发现使得模型的中间推理步骤成为重要研究对象。随后，一系列工作开始探索如何利用推理轨迹进行自动化验证。例如 Cobbe 等人提出 GSM8K 数据集并训练验证模型评估推理过程（Cobbe et al., 2021）。Lightman 等人提出 Process Supervision，通过对推理步骤逐步监督来提升推理正确率（Lightman et al., 2023）。

2. Chain-of-Thought 与数理推理能力

Chain-of-Thought 推理是近年来推动大模型在数学与逻辑推理任务中取得突破的关键技术。Wei 等人（2022）首次发现，大规模语言模型在提供推理示例后能够生成多步推理过程，从而显著提升复杂问题的求解能力。随后，研究者提出多种改进方法以提升推理稳定性。例如 Wang 等人提出 Self-Consistency，通过采样多条推理路径并进行投票来降低错误率（Wang et al., 2023）；Zhou 等人提出 Least-to-Most prompting，通过逐步分解问题提升推理成功率（Zhou et al., 2022）。

在数学领域，大模型的推理能力已在多个 benchmark 上得到系统评估。Hendrycks 等人提出 MATH 数据集，包含大量高难度数学竞赛题，被广泛用于评估模型的复杂推理能力（Hendrycks et al., 2021）。Cobbe 等人提出的 GSM8K 则主要评估基础数学推理能力（Cobbe et al., 2021）。此外，一些研究将 LLM 与程序执行环境结合，例如 PAL（Program-Aided Language Models），通过生成代码并执行来完成复杂计算任务（Gao et al., 2023）。

3. 物理领域大语言模型

随着科学智能研究的兴起，一些工作开始探索面向物理领域的大模型（Physics LLM）。这类模型旨在提升人工智能在科学知识理解、符号推导和科学发现中的能力。

Barman 等人提出 Large Physics Models (LPMs) 的概念框架，指出物理领域的大模型需要整合科学文本理解、符号计算、方程验证与多模态信息处理等能力，并构建专门的训练语料与评估体系（Barman et al., 2025）。此外，一些研究尝试利用大模型辅助科学发现。例如 Taskin 等人将 LLM 引入符号回归任务，使模型能够从实验数据中推测潜在的解析表达式或微分方程（Taskin et al., 2025）。

多智能体系统也是近期的重要研究方向。Yu 等人提出 PhysicsMinions 框架，通过多个智能体分别承担建模、计算和验证任务，在物理竞赛问题上取得较好的表现（Yu et al., 2025）。与此同时，多模态模型也被用于物理问题理解。Polverini 等人

研究表明，当前多模态 LLM 在物理图像题中的表现仍存在明显局限，视觉推理仍是关键挑战（Polverini et al., 2025）。

总体而言，Physics LLM 研究仍处于发展初期，但已展现出在科学问题求解与知识发现方面的重要潜力。

4. 大模型物理竞赛测试基准

为了系统评估大模型在科学推理任务中的能力，研究者构建了一系列物理问题 benchmark。早期数据集如 ARC、PhysicsQA 等主要关注基础科学知识问答（Clark et al., 2018）。然而，这类数据集难以充分评估复杂推理能力。

因此，近年来研究开始关注物理竞赛题 benchmark。例如 HiPhO（High-school Physics Olympiad Benchmark）收集了来自物理竞赛与奥林匹克竞赛的高难度题目，用于评估模型在复杂建模和多步推理中的能力。相关研究表明，当前最先进的大模型虽然在物理竞赛任务中可以达到接近人类专家水平，但其解题过程中仍然存在较多违背物理情境或物理规则的错误。

综上所述，尽管大模型在数学与科学推理任务中取得了显著进展，但在复杂物理问题求解中仍存在推理可靠性不足的问题。特别是在情景建模与解题策略选择阶段，模型容易产生系统性错误。因此，构建结合知识规则与推理过程验证的自动化检查机制，对于提升大模型在科学推理任务中的可靠性具有重要研究意义。

三、主要研究问题与拟采用的方法

（一）主要研究问题

1. 如何构建覆盖物理竞赛核心知识规则框架？
2. 如何将具体经验错误规则映射为更本质的知识规则与符号逻辑？
3. 如何解决情境错配的识别问题？
4. 如何在规则数量与泛化能力之间取得平衡？

（二）拟采用的方法

1. 知识规则框架构建

自顶向下设计规则框架：从力学、电磁学、空气动力学和统计物理、光学、现代物理、实验物理六个主题出发，结合物理教材和竞赛考纲设置细分主题，构建覆盖不同竞赛问题核心知识的规则框架。

自底向上收集经验规则：收集大量错误解答，并使用强语言模型对过程错误进行分析；将错误提炼为条件-结论式的经验规则，并将其划入到规则框架之中；在大量经验规则的收集和迭代中不断优化规则框架。

2. 规则翻译器设计

构建一个“知识规则到符号逻辑”映射模块：采用“符号检查模板+具体描述”的形式，将规则对应翻译为基于特定符号检查模板的具体描述，通过参数传递的方式得到可用的符号检查逻辑和代码。

3. 实验设计

对比实验：对比不同模型使用规则框架与否的检查效果

分析指标：错误覆盖率、检查准确率、检查质量

四、工作进度计划

第1-2周

- * 系统阅读相关文献
- * 明确知识规则框架结构
- * 设计规则层级体系

第3-4周

- * 收集物理竞赛题及错误解答
- * 初步完成规则框架的搭建

第5-6周

- * 构建符号检查模板
- * 初步实现规则到符号翻译器

第7-8周

- * 测试并优化符号翻译器
- * 迭代优化规则框架

第9-10周

- * 整合系统架构
- * 初步实验验证

第11-12周

- * 调整和优化检查策略
- * 扩展检查逻辑

第13-14周

- * 扩大实验规模
- * 进行对比实验
- * 消融实验和误差分析

第15-16周

- * 撰写论文
- * 完成总结和答辩准备

参考文献

Chi, M. T. H., Feltovich, P. J., & Glaser, R. (1981). Categorization and representation of physics problems by experts and novices. **Cognitive Science**, 5(2), 121–152.

Cobbe, K., et al. (2021). Training verifiers to solve math word problems. **arXiv preprint arXiv:2110.14168**.

Ellis, K., et al. (2021). DreamCoder: Bootstrapping inductive program synthesis. **PLDI**.

Garcez, A., et al. (2019). Neural-symbolic computing: An effective methodology. **AAAI**.

Nickel, M., et al. (2016). A review of relational machine learning for knowledge graphs. **Proceedings of the IEEE**.

Polu, S., & Sutskever, I. (2020). Generative language modeling for automated theorem proving. **arXiv preprint arXiv:2009.03393**.

Rocktäschel, T., & Riedel, S. (2017). End-to-end differentiable proving. **NeurIPS**.

Wang, X., et al. (2023). Self-consistency improves chain-of-thought reasoning in language models. **ICLR**.

Wei, J., et al. (2022). Chain-of-thought prompting elicits reasoning in large language models. **NeurIPS**.

Lightman, H., et al. (2023). Let’s verify step by step. *arXiv*.

Zhou, D., et al. (2022). Least-to-most prompting enables complex reasoning in large language models. *arXiv*.

Hendrycks, D., et al. (2021). Measuring mathematical problem solving with the MATH dataset. *NeurIPS*.

Gao, L., et al. (2023). PAL: Program-aided language models. *ICML*.

Barman, S., et al. (2025). Large Physics Models: Towards foundation models for physics. *arXiv*.

Taskin, B., et al. (2025). Knowledge integration for physics-informed symbolic regression. *arXiv*.

Yu, Z., et al. (2025). PhysicsMinions: Multi-agent reasoning for physics olympiad problems. *arXiv*.

Polverini, M., et al. (2025). Multimodal large language models and physics visual tasks: comparative analysis of performance and costs. *arXiv*.

Clark, P., et al. (2018). Think you have solved question answering? Try ARC. *arXiv*.